

Guia Completo do Projeto — Efeito Dominó no Mercado de Transferências

Grupo 02 · Ciência de Dados Aplicada ao Futebol · UFMG · 2026

Para quem é este documento: todos os integrantes do grupo, especialmente quem não acompanhou cada etapa em tempo real. Leia do início ao fim antes da apresentação. O objetivo é que qualquer um de nós consiga explicar qualquer parte do projeto com confiança.

Índice

1. [A Pergunta e a Hipótese](#)
 2. [Os Dados](#)
 3. [Feature Engineering](#)
 4. [Etapa 1 — Modelo Hedônico](#)
 5. [Etapa 2 — Double Machine Learning](#)
 6. [Testes de Robustez](#)
 7. [IVB — Índice de Vulnerabilidade de Barganha](#)
 8. [Os Três Achados Principais](#)
 9. [O Que Não Fizemos e Por Quê](#)
 10. [Glossário Rápido](#)
-

1. A Pergunta e a Hipótese

O que queríamos saber

Quando um clube de futebol faz uma grande venda — digamos, vende seu melhor jogador por €50M — ele fica com dinheiro em caixa e precisa repor o atleta. Os clubes vendedores sabem disso. A intuição do projeto é: **esse clube fica em desvantagem na negociação e acaba pagando mais caro do que deveria nas compras seguintes?**

Chamamos esse efeito de **"prêmio do vendedor"** — um sobrepreço pago pelo clube que acabou de vender.

Por que isso não é óbvio

A primeira resposta de qualquer pessoa seria: "é claro que existe — olha o Real Madrid, vende caro e compra caro também". **Mas isso é o problema.** Clubes grandes vendem por valores altos E compram por valores altos — não por causa do efeito de barganha, mas simplesmente porque são ricos. Se pegarmos todos os dados e fizermos uma correlação, vamos encontrar uma relação positiva entre "quanto vendeu" e "quanto pagou de sobrepreço" — mas essa correlação é falsa. É o clube rico aparecendo dos dois lados.

O desafio real do projeto é separar o efeito causal da liquidez do simples porte financeiro do

clube. Para isso, precisamos de uma estratégia metodológica cuidadosa — não podemos responder essa pergunta com uma regressão simples.

A pergunta operacional

Depois de refinar, nossa pergunta virou:

A liquidez recente do comprador (receita de vendas na temporada) tem efeito causal sobre o sobrepreço que ele paga em novas contratações, depois de neutralizar os confundidores estruturais?

Duas palavras importantes: **causal** (não correlação) e **depois de neutralizar confundidores** (controlando o clube rico e outros fatores).

Os 6 Confundidores Mapeados

Antes de modelar qualquer coisa, mapeamos 6 razões pelas quais poderíamos encontrar uma correlação espúria entre "recebeu de vendas" e "pagou sobrepreço":

ID	Confundidor	O que é	Como tratamos
C1	Clube rico	Clubes grandes vendem caro E compram caro	Controles de rede (PageRank) + elenco no vetor W
C2	Causalidade reversa	O clube planejou comprar caro e vendeu pra financiar	Teste de tratamento defasado (lag t-1)
C3	Causa comum	UCL, troca de técnico afeta vendas e compras	Não controlado (sem dados esportivos)
C4	Sazonalidade	Certas janelas são mais caras por natureza	Dummies de temporada em W e na Etapa 1
C5	Inflação de mercado	O mercado de 2023 é mais caro que 2017	Dummies de temporada absorvem inflação
C6	Viés de seleção	Clubes diferentes têm perfis de compra diferentes	Proxies de rede + tamanho de elenco em W

O fato de termos mapeado esses confundidores explicitamente **antes** de modelar é o que dá credibilidade metodológica ao trabalho. Não estamos ignorando os problemas — estamos tratando cada um deles.

2. Os Dados

Fonte

Usamos o **Transfermarkt** — o maior banco de dados de transferências de futebol do mundo —

via o repositório público [dcaribou/transfermarkt-datasets](https://github.com/dcaribou/transfermarkt-datasets). Os dados incluem:

- Todas as transferências de 7 ligas europeias (Premier League, La Liga, Bundesliga, Serie A, Ligue 1, Liga Portugal, Jupiler Pro League)
- Informações dos jogadores: idade, posição, valor de mercado
- Informações dos clubes: elenco, ligas, histórico de transações

O funil de filtragem

Começamos com **44.627 movimentações brutas** e terminamos com **5.146 transferências** para modelagem. Por quê tantos filtros?

Empréstimos e transferências gratuitas foram removidos porque não têm preço negociado — não faz sentido estudar sobrepreço onde não há preço.

Transfers abaixo de €250.000 foram removidos por uma razão empiricamente validada: abaixo desse valor, o indicador de sobrepreço tem variância muito baixa (desvio padrão < 0,30) e mediana fortemente negativa. Não há dinâmica real de mercado nessa faixa — são transações administrativas, muitas vezes jogadores saindo de graça mas com taxa de trâmite simbólica.

Transferências sem valor de mercado válido foram removidas porque o valor de mercado do Transfermarkt é a base do nosso "preço justo" na Etapa 1. Sem esse dado, não conseguimos calcular o resíduo.

As 8 Temporadas

O projeto começou com 3 temporadas (2023–2025) e foi expandido para **8 temporadas (2017–2025, exceto 2020)**. Por quê?

- Mais dados = estimativas mais precisas e ICs menores
- 8 temporadas permitem ver variação temporal real (boom pós-COVID em 2022–2023)
- 2020 está ausente porque a pandemia paralisou os mercados — os dados não foram coletados

Consequência importante: a expansão para 8 temporadas **mudou o resultado principal**.

Com 3 temporadas, o ATE era significativo ($\theta = 0,012$). Com 8 temporadas, o ATE médio ficou **não significativo** ($\theta = 0,003$). Isso não é uma falha — é um resultado mais honesto e rico. Explicamos por quê na seção 5.

3. Feature Engineering

O que é feature engineering

É o processo de criar as variáveis que vão entrar nos modelos a partir dos dados brutos. No nosso

caso, os dados brutos são tabelas de transferências e clubes — precisamos transformá-los em variáveis numéricas que capturem os conceitos que nos interessam.

Features do jogador (usadas na Etapa 1)

Essas variáveis descrevem o atleta e o contexto de mercado. Entram no modelo hedônico.

- **age** e **age_sq** : idade e idade ao quadrado. O quadrado é essencial porque a relação entre idade e valor não é linear — jogadores com ~20 anos valem mais que a curva linear sugeriria (potencial de crescimento), e depois dos 30 o valor cai mais rápido. Sem o termo quadrático, o modelo subestimaria o valor de jogadores jovens e superestimaria os veteranos.
- **log_mv** : logaritmo do valor de mercado do Transfermarkt. É o preditor mais forte — o mercado já "precificou" o jogador antes da transferência. Usamos logaritmo porque os valores variam de €250k a €200M — em escala linear, os outliers dominariam o modelo.
- **is_attacker** , **is_midfielder** , **is_defender** : dummies de posição. Atacantes comandam prêmios maiores em média. Base de comparação: goleiros e zagueiros.
- **Dummies de liga (6)**: Premier League, La Liga, Bundesliga (base), Serie A, Ligue 1, Liga Portugal, Jupiler Pro League. Ligas mais ricas têm inflação de preços própria.
- **Dummies de temporada (7)**: 2018, 2019, 2021, 2022, 2023, 2024, 2025 (base: 2017). Capturam a inflação geral do mercado ao longo do tempo.

Total: 19 features. Nenhuma feature de comportamento financeiro do clube comprador entra aqui — isso é um design intencional, explicado na Etapa 1.

Features do clube (usadas na Etapa 2)

Essas variáveis descrevem o comportamento do clube na temporada. Entram como confundidores (W) no Double ML.

- **revenue_sales** : soma de todos os fees recebidos em vendas. É a nossa **variável de tratamento principal (D)** — transforma-se em $D = \log(1 + \text{revenue_sales})$.
- **n_sales** : número de vendas realizadas. Alternativa de tratamento testada na robustez.
- **max_sale** : maior venda individual. Base para criar **big_sale_flag** (>€30M).

- **total_spend** , **n_buys** : controles do comportamento habitual de gasto do clube. Importantes para separar "teve dinheiro esta temporada" de "sempre gasta muito".

Features de rede (usadas na Etapa 2)

O mercado de transferências pode ser modelado como um **grafo dirigido**: nós são clubes, arestas são transferências, pesos são os fees pagos. Para cada temporada, construímos esse grafo e calculamos:

- **pagerank** : importância estrutural do clube na rede. Clubes que compram de outros clubes importantes têm PageRank alto. É a proxy mais robusta de "poder e prestígio" do clube.
- **in_degree** : quantos clubes diferentes venderam jogadores para este clube — mede a diversidade de parceiros de compra.
- **out_degree** : quantos clubes diferentes compraram deste clube — mede o alcance como vendedor.
- **in_strength** / **out_strength** : volume total (em €) de compras e vendas. O **out_strength** e **in_strength** capturam o mesmo conceito que **revenue_sales** mas pela perspectiva da rede.

Essas features de rede são importantes porque capturam o **poder estrutural de barganha** de um clube — algo que simples variáveis financeiras não capturam. O PSG e o Real Madrid dominam o PageRank; clubes menores têm PageRank baixo. Isso controla o confundidor C1 (clube rico) de forma mais sofisticada que uma dummy de liga.

4. Etapa 1 — Modelo Hedônico

O que é um modelo hedônico

Um "modelo hedônico" decompõe o preço de um bem na soma do valor de seus atributos. É usado em imóveis ("preço do apartamento = $f(\text{metros quadrados, localização, andar...})$ "), em

carros, em
vinhos. Aqui, aplicamos ao futebol:

Preço da transferência = f(atributos do jogador + contexto de mercado)

O que o modelo **não consegue explicar** — o resíduo — é o que sobra depois de remover o valor intrínseco do atleta. Esse resíduo é o nosso **sobrep preço** ou **prêmio de reinvestimento (Y)**.

Por que precisamos do modelo hedônico antes do DML

Se tentássemos medir o sobrep preço diretamente comparando o preço pago com o valor de mercado do

Transfermarkt, teríamos um proxy razoável. Mas o value de mercado do Transfermarkt também tem

erro — é uma estimativa humana, não o valor justo de ML. Ao treinar um modelo com 4 algoritmos

e 19 features, conseguimos uma estimativa mais precisa e menos enviesada do "preço justo".

Mais importante: **o modelo hedônico separa o que é do jogador do que é da negociação**. O

resíduo da Etapa 1 está livre de "ele pagou caro porque o jogador era muito bom". O que sobra

são as forças conjunturais da negociação — que é exatamente o que queremos medir na Etapa 2.

A decisão do split temporal

Treinamos em 2017–2024 e testamos em 2025. **Por que não aleatório?**

Divisão aleatória causaria data leakage temporal: o modelo veria dados do futuro no treino.

Em termos práticos, se misturarmos uma transferência de 2023 no teste e outra de 2023 no treino,

o modelo aprende padrões específicos daquele ano — mas na vida real, você sempre vai prever o

futuro a partir do passado. O split temporal simula o uso real e é um teste de generalização

mais honesto.

Os 4 modelos testados e por que

Testamos 4 algoritmos para ter certeza de que o resultado não depende da escolha do modelo:

Modelo	Test R^2	Test RMSE	Por que testar
Random Forest ✓	0,762	0,673	Ensemble robusto, sem overfitting por OOB
LightGBM	0,755	0,683	Boosting eficiente, compara com RF
XGBoost	0,746	0,694	Boosting clássico da literatura
SVR (RBF)	0,730	0,716	Kernel não-linear como contraste

Vencedor: Random Forest, por menor RMSE e maior R^2 no holdout. O gap pequeno entre os modelos (todos entre 0,73 e 0,76) é positivo — significa que o resultado é robusto à escolha do algoritmo.

Por que RMSE como métrica principal? Porque os fees variam de €250k a €200M em escala logarítmica. O RMSE penaliza erros grandes — que importam quando estamos falando de dezenas de milhões de euros.

O que o $R^2 = 0,762$ significa

76,2% da variância do log do fee de transferência é explicada por apenas 19 features do jogador e do contexto de mercado. É um resultado excelente para essa aplicação — a literatura acadêmica de valuation de jogadores tipicamente reporta R^2 entre 0,70 e 0,80.

Os 23,8% não explicados incluem: contexto tático específico do clube comprador, urgência do negócio, relacionamento entre presidentes, cláusulas de bônus não divulgadas, pressão de torcida.

Parte desse "ruído" é o nosso objeto de estudo na Etapa 2.

O SHAP e o que ele revela

SHAP (SHapley Additive exPlanations) é uma técnica de interpretabilidade que calcula a contribuição de cada feature para cada predição. Para o nosso modelo:

1. **log_mv domina** — o valor de mercado do Transfermarkt explica a maior parte do preço.
Isso valida o dado: Transfermarkt precifica bem os jogadores.
2. **age e age_sq** vêm em seguida — a curvatura biológica do valor é capturada.
3. Dummies de **liga e posição** têm impacto secundário.

Isso é o resultado esperado e dá credibilidade ao modelo. Se uma feature estranha dominasse, teríamos um problema.

O resíduo: nossa variável Y

$$Y_i = \ln(P_i) - \ln(\hat{P}_i)$$

- $Y > 0$: clube pagou acima do preço justo → sobrepreço (prêmio)
- $Y = 0$: clube pagou exatamente o valor justo
- $Y < 0$: clube fez um bom negócio — comprou abaixo do valor justo

51,7% das transferências têm $Y > 0$ — mais da metade do mercado paga algum prêmio.

A mediana

é +1,9%, o que significa um leve sobrepreço típico. Mas atenção: isso não significa que o prêmio

do vendedor existe — pode ser simplesmente que o mercado sempre tem um small ágio médio por

incerteza e urgência. O efeito causal da liquidez é testado na Etapa 2.

5. Etapa 2 — Double Machine Learning

O problema que o DML resolve

Queremos estimar o efeito causal θ de D (liquidez) em Y (sobrepreço). Se fizéssemos só uma

regressão $Y \sim D$, o coeficiente de D seria enviesado pelos confundidores W (clube rico, sazonalidade, etc.). Se adicionássemos W na regressão ($Y \sim D + W$), o problema seria:

1. A relação entre W e Y pode ser não-linear (Random Forest captura isso, OLS não)
2. Temos 19 confundidores — incluí-los em OLS aumenta o erro e pode criar overfitting

O **Double ML** (Chernozhukov et al., 2018) resolve os dois problemas com uma técnica elegante

chamada **ortogonalização de Neyman**. A ideia em 3 passos:

Passo 1: Tire de Y o que os confundidores W explicam → resíduo $\tilde{Y} = Y - \hat{g}(W)$

Passo 2: Tire de D o que os confundidores W explicam → resíduo $\tilde{D} = D - \hat{m}(W)$

Passo 3: Estime θ pela regressão simples $\tilde{Y} \sim \theta \cdot \tilde{D}$

Por que isso funciona? $\tilde{Y}$ e $\tilde{D}$ são as partes de Y e D que os confundidores não conseguem

explicar. Ao regredir $\tilde{Y}$ em $\tilde{D}$, estamos medindo a relação entre "variação de liquidez que não

é explicada pelo porte do clube" e "variação de sobrepreço que não é explicada pelo porte do clube". Essa relação é, por construção, livre do confundidor C1.

O cross-fitting e por que é necessário

Se treinarmos $\hat{g}$ e $\hat{m}$ nos mesmos dados onde calculamos os resíduos, o modelo pode "memorizar" os dados de treino e os resíduos ficarão artificialmente pequenos — um tipo de overfitting que viesaria θ .

Cross-fitting (K=5 folds): dividimos os dados em 5 partes. Para cada parte, treinamos $\hat{g}$ e $\hat{m}$ nas outras 4 e calculamos os resíduos na parte deixada de fora. Ao final, temos resíduos out-of-sample para todas as observações — sem overfitting.

O vetor de confundidores W (19 variáveis)

Bloco	Variáveis	Confundidor controlado
Rede	<code>in_degree</code> , <code>out_degree</code> , <code>pagerank</code>	C1 (clube rico/prestígio), C6
Elenco	<code>squad_size</code> , <code>average_age</code> , <code>national_team_players</code>	C1, C6
Temporada	7 dummies (2018–2025)	C4 (sazonalidade), C5 (inflação)
Liga	6 dummies	C4, C5

Limitação importante: W não inclui `total_spend`, `n_buys`, `net_balance` (bloco financeiro direto). O confundidor C1 é controlado por proxies (centralidade na rede + tamanho do elenco), não pelo volume financeiro direto. Isso é uma limitação reconhecida — declaramos nas limitações.

O resultado principal: ATE = 0,003 (não significativo)

ATE (Average Treatment Effect) = efeito médio causal. O que significa $\theta = 0,003$?

Para cada 1% de aumento na receita de vendas do clube, o sobrepreço nas compras aumenta em média 0,003 pontos percentuais. **O IC 95% é $[-0,002; 0,008]$ — cruza zero.** Não

podemos
rejeitar a hipótese de que o efeito é zero.

Por que isso é um resultado válido e não uma falha?

Porque o contraste com a correlação ingênua revela algo importante:

Estimador	θ	IC 95%	Significativo?
OLS sem controles ($Y \sim D$)	0,012	[0,007; 0,016]	Sim
OLS com controles lineares	0,004	[-0,001; 0,009]	Não
DML (não-linear)	0,003	[-0,002; 0,008]	Não

A progressão é clara: à medida que controlamos os confundidores de forma cada vez mais adequada,
o efeito estimado encolhe de 0,012 para 0,003 e perde significância. **Isso mostra que a correlação bruta (0,012) era, em grande parte, o confundidor "clube rico" em ação.** O DML separou o efeito real do ruído de confundimento.

Os placebos: validando que o modelo não inventa efeito

Dois testes de sanidade:

Placebo 1 — D embaralhado: embaralhamos aleatoriamente quem recebeu qual valor de receita

de vendas. Se o modelo encontrar um efeito aqui, ele está inventando efeito onde não há. Resultado:

$\theta = 0,0023$ (IC cruza zero) ✓

Placebo 2 — D → ruído gaussiano: substituímos D por números aleatórios. Resultado:

$\theta = 0,0006$ (IC cruza zero) ✓

Atenção: o placebo embaralhado deu $\theta = 0,0023$ — quase do tamanho do ATE real (0,0031).

Isso reforça que o ATE médio é genuinamente nulo: o modelo mal consegue distinguir o tratamento

real do ruído. Esse padrão é coerente com a conclusão de ausência de efeito médio.

O R^2 da primeira etapa

Antes de estimar θ , o DML precisa que os modelos $\hat{g}$ e $\hat{m}$ funcionem minimamente bem:

- **R^2 model_t ($\hat{m}$) = 0,37:** os confundidores W explicam 37% da variância da receita de vendas.

Razoável — o porte do clube prediz razoavelmente bem quanto ele vende.

- **$R^2 \text{ model_y } (\hat{\eta}) = 0,06$** : os confundidores W explicam apenas 6% da variância do sobrepreço.
Baixo, mas esperado: Y já é o resíduo da Etapa 1 (jogador foi removido). O que sobra é majoritariamente idiossincrático.

O achado central: θ por temporada

Quando olhamos o efeito separado por temporada, a história muda completamente:

Temporada	θ	IC 95%	Significativo?	Contexto
2017	-0,006	[-0,026; 0,014]	Não	Mercado normal
2018	-0,014	[-0,040; 0,012]	Não	Mercado normal
2019	+0,016	[-0,011; 0,044]	Não	Mercado normal
2021	+0,011	[-0,002; 0,025]	Não	Pós-COVID (cautela)
2022	+0,052	[0,012; 0,092]	Sim	Boom pós-COVID
2023	+0,039	[0,003; 0,075]	Sim	Boom pós-COVID
2024	+0,003	[-0,053; 0,059]	Não	Normalização
2025	+0,013	[-0,017; 0,042]	Não	Normalização

O que isso significa:

Em 2022 e 2023, o mercado de transferências viveu um boom sem precedentes após 2 anos de restrições pandêmicas. Os volumes bateram recordes. Nesse contexto de escassez de talento disponível e urgência generalizada de reposição, o prêmio do vendedor emergiu: clubes com liquidez pagavam +5,2% (2022) e +3,9% (2023) acima do preço justo.

Nos outros 6 anos, o efeito é estatisticamente zero. A média das 8 temporadas dilui o efeito de 2022–2023 com 6 anos de zero — daí o ATE médio ser nulo.

Por que a versão de 3 temporadas parecia significativa? Porque usava 2023–2025, e 2023 era o ano mais forte. Com mais dados, o contexto ficou claro: não é sempre — é só quando o mercado aquece.

6. Testes de Robustez

O que são testes de robustez e por que fazemos

Um resultado robusto é aquele que não muda quando fazemos variações razoáveis na metodologia.

Se o efeito desaparece quando mudamos levemente o tratamento ou a amostra, o resultado original não era confiável. Fizemos 4 tipos de teste.

Teste 1 — Tratamento Defasado (C2 — Causalidade Reversa)

O problema: medimos D (receita de vendas) e Y (sobrepço das compras) na **mesma temporada**.

Isso deixa a dúvida: e se o clube primeiro decidiu comprar caro e depois vendeu para pagar?

Nesse caso, a compra causaria a venda — e não o contrário.

A solução: usamos a receita de vendas do **ano anterior** ($t-1$) como tratamento alternativo.

A receita de $t-1$ é predeterminada em relação à compra de t — uma compra de 2024 não pode ter causado as vendas de 2023.

Resultado: $\theta_{\text{defasado}} = 0,0038^*$ (IC [0,0003; 0,0073]) — significativo.

O que significa: quando usamos a liquidez do ano anterior, o efeito persiste e é significativo. Se o efeito fosse de causalidade reversa (compra $\rightarrow$ venda), usar o ano anterior deveria zerar o coeficiente. Como não zeramos, a direção "venda $\rightarrow$ prêmio" é mais plausível.

A causalidade reversa (C2) fica enfraquecida — não eliminada, mas menos provável.

Teste 2 — D Alternativo (Especificações do Tratamento)

O problema: medimos liquidez como $D = \log(\text{receita em euros})$. Mas e se o mecanismo for diferente? E se não for o volume de dinheiro, mas outra coisa?

Testamos 3 definições:

Tratamento	Interpretação	θ	Significativo?
$D_1 = \log(\text{receita } \text{€})$ — principal	Volume de dinheiro recebido	0,003	Não
$D_2 = \log(\text{n}^\circ \text{ de vendas})$	Quantas vendas foram feitas	0,036	Sim
$D_3 = \text{flag de venda} > \text{€}30\text{M}$	Fez uma venda blockbuster?	0,060	Sim

O que significa — este é o achado mais importante do projeto:

D_1 (volume em euros) não prediz sobrepreço. Mas D_2 (número de vendas) e D_3 (venda blockbuster)

sim. Por quê?

- **D_2 :** um clube que vendeu 8 jogadores na temporada precisa repor 8 — há urgência de múltiplas reposições simultâneas. Os vendedores sabem que ele vai ao mercado de qualquer jeito. Essa pressão de reposição múltipla ativa o prêmio.
- **D_3 :** uma venda de €50M de um ativo-chave sinaliza abertamente ao mercado: "esse clube vai comprar um substituto". Os preços sobem antes da negociação começar.

O mecanismo não é "ter dinheiro" — é "sinalizar que precisa comprar".

Um clube que vendeu por €50M em receitas concentradas em uma única venda (D_1 alto mas $D_3 = 1$)

ativa o prêmio. Um clube que vendeu €50M em 10 vendas pequenas (D_1 alto e D_2 alto) também

ativa, mas pelo mecanismo de urgência de reposição múltipla.

Isso é mais fiel à intuição original do "efeito dominó" do que a medida de volume em euros.

Teste 3 — Subgrupos por Tier de Liga

Dividimos as transferências em duas categorias:

- **Top-4:** Bundesliga, Premier League, La Liga, Serie A (3.450 obs) $\rightarrow \theta = 0,0036$ (n.s.)
- **Ligas menores:** Jupiler Pro League, Liga Portugal, Ligue-1 (1.696 obs) $\rightarrow \theta = 0,0089$ (n.s.)

O que significa: nenhum grupo tem efeito significativo na média das 8 temporadas — coerente

com o ATE geral nulo. Mas a **direção** está certa: ligas menores têm θ maior, o que é consistente

com a teoria (clubes de ligas menores são tipicamente vendedores e sofrem mais

pressão de reposição). A falta de significância é provavelmente falta de poder estatístico (n menor).

Teste 4 — Placebos (já descrito na Etapa 2)

D embaralhado: $\theta = 0,002$ (n.s.) ✓

D com ruído: $\theta = 0,001$ (n.s.) ✓

7. IVB — Índice de Vulnerabilidade de Barganha

O que é

O IVB é um índice que pontua cada clube de 0 a 1 com base em quanto ele sofre o efeito do prêmio do vendedor quando tem liquidez.

$$IVB_c = \frac{\theta_c - \min(\Theta)}{\max(\Theta) - \min(\Theta)}$$

- **IVB ≈ 1 ("presa fácil")**: clube que paga os maiores sobrepreços quando capitalizado
- **IVB ≈ 0 ("negociador disciplinado")**: clube que não deixa a liquidez afetar suas compras

O CATE (efeito causal individual estimado por clube) vira o IVB após normalização.

Como foi calculado

Usamos o **R-learner** (Nie & Wager, 2021) — uma variante do DML que estima um efeito por

observação ao invés de um único ATE médio. O CATE de cada observação é então agregado por clube

(média das transferências do clube que tenham ≥ 3 observações para estabilidade).

Limitação importante: o desenho original previa `CausalForestDML` do pacote `econml`. O `econml`

não instala no nosso ambiente (Python 3.12 + NumPy 2.x têm incompatibilidade de build). O

R-learner é uma aproximação válida, mas os números **não são diretamente comparáveis** com o

que o `econml` daria. Por isso o IVB deve ser tratado como **ilustrativo**.

O problema do outlier e da normalização min-max

O ranking atual tem Nîmes Olympique no topo (IVB $\approx 0,41$) — um clube da Ligue 1 com poucas

transferências na base. O problema: a normalização min-max divide pelo range (max – min). Se

um outlier tem CATE muito alto, o max explode, e todos os outros clubes ficam comprimidos perto de zero. **O Nîmes domina o denominador e distorce o ranking.**

Por isso não usamos o IVB como ranking definitivo, mas como prova de conceito de ferramenta de inteligência de mercado.

O que seria se funcionasse corretamente

Com `CausalForestDML` e sem o problema do outlier, o IVB seria uma ferramenta real para:

- Um clube identificar, antes de negociar, quais rivais são mais vulneráveis à exploração quando estão capitalizados
- Um clube verificar se ele mesmo é uma "presa fácil" e ajustar sua estratégia de timing

8. Os Três Achados Principais

Achado 1 — A Correlação Mente

OLS ingênuo: $\theta = 0,012^*$ (significativo)

DML causal: $\theta = 0,003$ (não significativo)

A correlação bruta entre "recebeu de vendas" e "pagou sobrepreço" é 4× maior que o efeito causal

real — e enganosamente significativa. Isso é o confundidor "clube rico" contaminando a correlação.

Sem o Double ML, teríamos publicado um resultado falso.

Mensagem: em análise de dados de futebol (e de mercados em geral), correlação não é causalidade. O pipeline causal de duas etapas que desenvolvemos é o que torna o resultado defensável.

Achado 2 — O Prêmio é Condicional ao Regime

Na média de 8 temporadas, o efeito é nulo. Mas em **2022 (+5,2%*) e 2023 (+3,9%*)** — o boom

pós-COVID — o prêmio emerge de forma significativa. Nos outros 6 anos, não há efeito detectável.

Mensagem: o "efeito dominó" não é uma lei do mercado — é um fenômeno emergente em condições específicas de escassez e urgência generalizada. O timing importa.

Achado 3 — O Mecanismo é Sinalização, Não Volume

Volume em euros (D_1): não prediz sobrepreço.

Número de vendas (D_2): prediz sobrepreço (+3,6%*).

Venda blockbuster >€30M (D_3): prediz sobrepreço (+6,0%*).

Mensagem: o clube não paga mais porque tem mais dinheiro — paga mais porque sinalizou ao mercado que precisa comprar. A urgência de reposição (D_2) e a venda de ativo-chave (D_3) são as formas de sinalização que ativam o prêmio. O volume monetário total (D_1) não é o gatilho.

9. O Que Não Fizemos e Por Quê

É importante ser honesto sobre o que prometemos e não entregamos, para não ser pego de surpresa na banca.

PSM (Propensity Score Matching)

Prometemos: o checkpoint mencionava "clubes gêmeos" via PSM para validar C6 (viés de seleção).

Não fizemos porque: o PSM exige que tratados e controles tenham distribuições de confundidores sobreponíveis. Com 19 confundidores, o matching seria complexo e provavelmente reduziria muito a amostra. Com o tempo disponível, priorizamos o DML (que controla confundidores de forma mais flexível) e os testes de robustez.

Como responder na banca: "O PSM foi substituído pelo controle não-paramétrico via DML, que trata os confundidores de forma mais flexível. Está declarado como trabalho futuro."

FBref / StatsBomb (dados de performance)

Prometemos: integrar gols, xG, assistências, minutagem para melhorar o modelo hedônico.

Não fizemos porque: o entity matching entre Transfermarkt e FBref exige reconciliar IDs de jogadores entre os dois sistemas — um processo demorado e sujeito a erros. Com o R^2

= 0,762 já

na faixa da literatura, a prioridade foi a robustez causal, não o refinamento do hedônico.

Como responder na banca: "O R^2 de 0,762 está na faixa esperada pela literatura (0,70–0,80).

A performance individual enriqueceria o hedônico mas está além do escopo atual."

econml / CausalForestDML

Prometemos: usar `CausalForestDML` do econml para o IVB.

Não fizemos porque: incompatibilidade de build no ambiente (Python 3.12 + NumPy 2.x).

O

R-learner foi usado como substituto para o CATE/IVB. O ATE e os testes de robustez usam DML

manual que é equivalente ao econml para o modelo parcialmente linear.

Como responder na banca: "O ATE e a robustez foram calculados com DML manual validado

(reproduz o econml dentro de erro de arredondamento). O IVB é ilustrativo —

declaramos essa

limitação explicitamente."

Análise do lado vendedor ("clubes predadores")

O IVB mede quem é vulnerável quando compra. A análise simétrica seria: quais clubes se

aproveitam melhor quando o outro lado está capitalizado e urgente? Isso não foi implementado

— mencionamos como trabalho futuro.

10. Glossário Rápido

Termo	Definição simples
Modelo hedônico	Modelo que prevê o preço de um bem pelos seus atributos. Aqui: preço do jogador pelos seus atributos esportivos.
Resíduo hedônico	Diferença entre o preço pago e o preço previsto pelo modelo. Nosso $Y = o$ sobrepreço.
ATE	Average Treatment Effect — efeito médio causal do tratamento (liquidez) sobre o resultado (sobrepreço).
CATE	Conditional Average Treatment Effect — efeito causal estimado individualmente para cada clube/observação.
DML	Double Machine Learning — método causal que usa dois modelos ML para eliminar confundidores não-lineares.
Ortogonalização de Neyman	A técnica dentro do DML de tirar o efeito de W de Y e de D antes de estimar θ .
Cross-fitting	Técnica de dividir os dados em K folds para evitar overfitting nos modelos de primeira etapa do DML.
HC1	Tipo de erro-padrão robusto à heterocedasticidade. Mais conservador que o SE clássico.
Confundidor	Variável que afeta tanto o tratamento quanto o resultado, criando correlação espúria.
Causalidade reversa (C2)	Quando o resultado causa o tratamento, não o contrário. Aqui: "comprou caro então vendeu" ao invés de "vendeu então comprou caro".
R-learner	Algoritmo de CATE que segue a lógica do DML mas estima efeitos individuais. Usado como substituto do CausalForestDML.
IVB	Índice de Vulnerabilidade de Barganha — score 0–1 do quanto cada clube sofre o prêmio quando capitalizado.
PageRank	Métrica de centralidade em grafo. Aqui: importância estrutural do clube na rede de transferências.
Big sale flag	Variável binária: 1 se o clube fez uma venda única acima de €30M na temporada.
Split temporal	Divisão de dados onde treino = passado e teste = futuro. Mais honesto que divisão aleatória para dados com tendência temporal.
Winsorização	Truncar os extremos da distribuição (aqui, percentis 1% e 99%) para reduzir o impacto de outliers.

Termo	Definição simples
SHAP	Técnica de interpretabilidade que calcula a contribuição de cada feature para cada predição individual.
IC 95%	Intervalo de Confiança de 95%. Se cruza zero, o efeito não é estatisticamente significativo a 5%.

Documento gerado em 18/06/2026. Dúvidas: releia as seções relevantes ou consulte os notebooks

em [notebooks/](#) e a documentação técnica em [knowledge/](#).