

Guia Completo do Projeto — Efeito Dominó no Mercado de Transferências

Grupo 02 · Ciência de Dados Aplicada ao Futebol · UFMG · 2026

Para quem é este documento: todos os integrantes do grupo, especialmente quem não acompanhou cada etapa em tempo real. Leia do início ao fim antes da apresentação. O objetivo é que qualquer um de nós consiga explicar qualquer parte do projeto com confiança.

Índice

1. A Pergunta e a Hipótese
2. Os Dados
3. Feature Engineering
4. Etapa 1 — Modelo Hedônico
5. Etapa 2 — Double Machine Learning
6. Testes de Robustez
7. IVB — Índice de Vulnerabilidade de Barganha
8. Os Três Achados Principais
9. O Que Não Fizemos e Por Quê
10. Glossário Rápido

1. A Pergunta e a Hipótese

O que queríamos saber

Quando um clube de futebol faz uma grande venda — digamos, vende seu melhor jogador por €50M — ele fica com dinheiro em caixa e precisa repor o atleta. Os clubes vendedores sabem disso. A intuição do projeto é: **esse clube fica em desvantagem na negociação e acaba pagando mais caro do que deveria nas compras seguintes?**

Chamamos esse efeito de “**prêmio do vendedor**” — um sobrepreço pago pelo clube que acabou de vender.

Por que isso não é óbvio

A primeira resposta de qualquer pessoa seria: “é claro que existe — olha o Real Madrid, vende caro e compra caro também”. **Mas isso é o problema.** Clubes grandes vendem por valores altos E compram por valores altos — não por causa do efeito de barganha, mas simplesmente porque são ricos. Se pegarmos todos os dados e fizermos uma correlação, vamos encontrar uma relação positiva entre “quanto vendeu” e “quanto pagou de sobrepreço” — mas essa correlação é falsa. É o clube rico aparecendo dos dois lados.

O desafio real do projeto é separar o efeito causal da liquidez do simples porte financeiro do clube. Para isso, precisamos de uma estratégia metodológica cuidadosa — não podemos responder essa pergunta com uma regressão simples.

A pergunta operacional

Depois de refinar, nossa pergunta virou:

A liquidez recente do comprador (receita de vendas na temporada) tem efeito causal sobre o sobrepreço que ele paga em novas contratações, depois de neutralizar os confundidores estruturais?

Duas palavras importantes: **causal** (não correlação) e **depois de neutralizar confundidores** (controlando o clube rico e outros fatores).

Os 6 Confundidores Mapeados

Antes de modelar qualquer coisa, mapeamos 6 razões pelas quais poderíamos encontrar uma correlação espúria entre “recebeu de vendas” e “pagou sobrepreço”:

ID	Confundidor	O que é	Como tratamos
C1	Clube rico	Clubes grandes vendem caro E compram caro	Controles de rede (PageRank) + elenco no vetor W
C2	Causalidade reversa	O clube planejou comprar caro e vendeu pra financiar	Teste de tratamento defasado (lag t-1)
C3	Causa comum	UCL, troca de técnico afeta vendas e compras	Não controlado (sem dados esportivos)
C4	Sazonalidade	Certas janelas são mais caras por natureza	Dummies de temporada em W e na Etapa 1
C5	Inflação de mercado	O mercado de 2023 é mais caro que 2017	Dummies de temporada absorvem inflação
C6	Viés de seleção	Clubes diferentes têm	Proxies de rede + tamanho de elenco em W

ID	Confundidor	O que é	Como tratamos
		perfis de compra diferentes	

O fato de termos mapeado esses confundidores explicitamente **antes** de modelar é o que dá credibilidade metodológica ao trabalho. Não estamos ignorando os problemas — estamos tratando cada um deles.

2. Os Dados

Fonte

Usamos o **Transfermarkt** — o maior banco de dados de transferências de futebol do mundo — via o repositório público `dcaribou/transfermarkt-datasets`. Os dados incluem:

- Todas as transferências de 7 ligas europeias (Premier League, La Liga, Bundesliga, Serie A, Ligue 1, Liga Portugal, Jupiler Pro League)
- Informações dos jogadores: idade, posição, valor de mercado
- Informações dos clubes: elenco, ligas, histórico de transações

O funil de filtragem

Começamos com **44.627 movimentações brutas** e terminamos com **5.146 transferências** para modelagem. Por quê tantos filtros?

Empréstimos e transferências gratuitas foram removidos porque não têm preço negociado — não faz sentido estudar sobrepreço onde não há preço.

Transfers abaixo de €250.000 foram removidos por uma razão empiricamente validada: abaixo desse valor, o indicador de sobrepreço tem variância muito baixa (desvio padrão $< 0,30$) e mediana fortemente negativa. Não há dinâmica real de mercado nessa faixa — são transações administrativas, muitas vezes jogadores saindo de graça mas com taxa de trâmite simbólica.

Transferências sem valor de mercado válido foram removidas porque o valor de mercado do Transfermarkt é a base do nosso “preço justo” na Etapa 1. Sem esse dado, não conseguimos calcular o resíduo.

As 8 Temporadas

O projeto começou com 3 temporadas (2023–2025) e foi expandido para **8 temporadas (2017–2025, exceto 2020)**. Por quê?

- Mais dados = estimativas mais precisas e ICs menores
- 8 temporadas permitem ver variação temporal real (boom pós-COVID em 2022–2023)

- 2020 está ausente porque a pandemia paralisou os mercados — os dados não foram coletados

Consequência importante: a expansão para 8 temporadas **mudou o resultado principal**. Com 3 temporadas, o ATE era significativo ($\theta = 0,012$). Com 8 temporadas, o ATE médio ficou **não significativo** ($\theta = 0,0044$). Isso não é uma falha — é um resultado mais honesto e mais rico. Explicamos por quê na seção 5.

3. Feature Engineering

O que é feature engineering

É o processo de criar as variáveis que vão entrar nos modelos a partir dos dados brutos. No nosso caso, os dados brutos são tabelas de transferências e clubes — precisamos transformá-los em variáveis numéricas que capturem os conceitos que nos interessam.

Features do jogador (usadas na Etapa 1)

Essas variáveis descrevem o atleta e o contexto de mercado. Entram no modelo hedônico.

- **age e age_sq:** idade e idade ao quadrado. O quadrado é essencial porque a relação entre idade e valor não é linear — jogadores com ~20 anos valem mais que a curva linear sugeriria (potencial de crescimento), e depois dos 30 o valor cai mais rápido. Sem o termo quadrático, o modelo subestimaria o valor de jogadores jovens e superestimaria os veteranos.
- **log_mv:** logaritmo do valor de mercado do Transfermarkt. É o preditor mais forte — o mercado já “precificou” o jogador antes da transferência. Usamos logaritmo porque os valores variam de €250k a €200M — em escala linear, os outliers dominariam o modelo.
- **is_attacker, is_midfielder, is_defender:** dummies de posição. Atacantes comandam prêmios maiores em média. Base de comparação: goleiros e zagueiros.
- **Dummies de liga (6):** Premier League, La Liga, Bundesliga (base), Serie A, Ligue 1, Liga Portugal, Jupiler Pro League. Ligas mais ricas têm inflação de preços própria.
- **Dummies de temporada (7):** 2018, 2019, 2021, 2022, 2023, 2024, 2025 (base: 2017). Capturam a inflação geral do mercado ao longo do tempo.

Total: 19 features. Nenhuma feature de comportamento financeiro do clube comprador entra aqui — isso é um design intencional, explicado na Etapa 1.

Features do clube (usadas na Etapa 2)

Essas variáveis descrevem o comportamento do clube na temporada. Entram como confundidores (W) no Double ML.

- **revenue_sales:** soma de todos os fees recebidos em vendas. É a nossa **variável de tratamento principal (D)** — transforma-se em $D = \log(1 + \text{revenue_sales})$.
- **n_sales:** número de vendas realizadas. Alternativa de tratamento testada na robustez.
- **max_sale:** maior venda individual. Base para criar `big_sale_flag` ($>€30M$).
- **total_spend, n_buys:** controles do comportamento habitual de gasto do clube. Importantes para separar “teve dinheiro esta temporada” de “sempre gasta muito”.

Features de rede (usadas na Etapa 2)

O mercado de transferências pode ser modelado como um **grafo dirigido**: nós são clubes, arestas são transferências, pesos são os fees pagos. Para cada temporada, construímos esse grafo e calculamos:

- **pagerank:** importância estrutural do clube na rede. Clubes que compram de outros clubes importantes têm PageRank alto. É a proxy mais robusta de “poder e prestígio” do clube.
- **in_degree:** quantos clubes diferentes venderam jogadores para este clube — mede a diversidade de parceiros de compra.
- **out_degree:** quantos clubes diferentes compraram deste clube — mede o alcance como vendedor.
- **in_strength / out_strength:** volume total (em €) de compras e vendas. O `out_strength` e `in_strength` capturam o mesmo conceito que `revenue_sales` mas pela perspectiva da rede.

Essas features de rede são importantes porque capturam o **poder estrutural de barganha** de um clube — algo que simples variáveis financeiras não capturam. O PSG e o Real Madrid dominam o PageRank; clubes menores têm PageRank baixo. Isso controla o confundidor C1 (clube rico) de forma mais sofisticada que uma dummy de liga.

4. Etapa 1 — Modelo Hedônico

O que é um modelo hedônico

Um “modelo hedônico” decompõe o preço de um bem na soma do valor de seus atributos. É usado em imóveis (“preço do apartamento = $f(\text{metros quadrados, localização, andar...})$ ”), em carros, em vinhos. Aqui, aplicamos ao futebol:

$$\text{Preço da transferência} = f(\text{atributos do jogador} + \text{contexto de mercado})$$

O que o modelo **não consegue explicar** — o resíduo — é o que sobra depois de remover o valor intrínseco do atleta. Esse resíduo é o nosso **sobrep preço** ou **prêmio de reinvestimento (Y)**.

Por que precisamos do modelo hedônico antes do DML

Se tentássemos medir o sobrepreço diretamente comparando o preço pago com o valor de mercado do Transfermarkt, teríamos um proxy razoável. Mas o value de mercado do Transfermarkt também tem erro — é uma estimativa humana, não o valor justo de ML. Ao treinar um modelo com 4 algoritmos e 19 features, conseguimos uma estimativa mais precisa e menos enviesada do “preço justo”.

Mais importante: **o modelo hedônico separa o que é do jogador do que é da negociação**. O resíduo da Etapa 1 está livre de “ele pagou caro porque o jogador era muito bom”. O que sobra são as forças conjunturais da negociação — que é exatamente o que queremos medir na Etapa 2.

A decisão do split temporal

Treinamos em 2017–2024 e testamos em 2025. **Por que não aleatório?**

Divisão aleatória causaria *data leakage* temporal: o modelo veria dados do futuro no treino. Em termos práticos, se misturarmos uma transferência de 2023 no teste e outra de 2023 no treino, o modelo aprende padrões específicos daquele ano — mas na vida real, você sempre vai prever o futuro a partir do passado. O split temporal simula o uso real e é um teste de generalização mais honesto.

Os 4 modelos testados e por que

Testamos 4 algoritmos para ter certeza de que o resultado não depende da escolha do modelo:

Modelo	Test R ²	Test RMSE	Por que testar
Random Forest 	0,762	0,673	Ensemble robusto, sem overfitting por OOB
LightGBM	0,755	0,683	Boosting eficiente, compara com RF
XGBoost	0,746	0,694	Boosting clássico da literatura
SVR (RBF)	0,730	0,716	

Modelo	Test R ²	Test RMSE	Por que testar
			Kernel não-linear como contraste

Vencedor: Random Forest, por menor RMSE e maior R² no holdout. O gap pequeno entre os modelos (todos entre 0,73 e 0,76) é positivo — significa que o resultado é robusto à escolha do algoritmo.

Por que RMSE como métrica principal? Porque os fees variam de €250k a €200M em escala logarítmica. O RMSE penaliza erros grandes — que importam quando estamos falando de dezenas de milhões de euros.

O que o R² = 0,762 significa

76,2% da variância do log do fee de transferência é explicada por apenas 19 features do jogador e do contexto de mercado. É um resultado excelente para essa aplicação — a literatura acadêmica de valuation de jogadores tipicamente reporta R² entre 0,70 e 0,80.

Os 23,8% não explicados incluem: contexto tático específico do clube comprador, urgência do negócio, relacionamento entre presidentes, cláusulas de bônus não divulgadas, pressão de torcida. Parte desse “ruído” é o nosso objeto de estudo na Etapa 2.

O SHAP e o que ele revela

SHAP (SHapley Additive exPlanations) é uma técnica de interpretabilidade que calcula a contribuição de cada feature para cada predição. Para o nosso modelo:

1. **log_mv domina** — o valor de mercado do Transfermarkt explica a maior parte do preço. Isso valida o dado: Transfermarkt precifica bem os jogadores.
2. **age e age_sq** vêm em seguida — a curvatura biológica do valor é capturada.
3. Dummies de **liga e posição** têm impacto secundário.

Isso é o resultado esperado e dá credibilidade ao modelo. Se uma feature estranha dominasse, teríamos um problema.

O resíduo: nossa variável Y

$$Y_i = \ln(P_i) - \ln(\hat{P}_i)$$

- **Y > 0**: clube pagou acima do preço justo → sobrepreço (prêmio)
- **Y = 0**: clube pagou exatamente o valor justo
- **Y < 0**: clube fez um bom negócio — comprou abaixo do valor justo

52,5% das transferências têm Y > 0 (resíduo out-of-fold) — mais da metade do mercado paga algum prêmio. A mediana é +3,5%, um leve sobrepreço típico. Mas atenção: isso não significa que o prêmio do vendedor existe — pode ser simplesmente que o mercado sempre tem um pequeno ágio médio por incerteza e urgência. O efeito causal da liquidez é testado na Etapa 2.

Nota metodológica (correção importante): o resíduo é gerado **out-of-fold** (`cross_val_predict`), não prevendo o próprio dado de treino. Isso evita resíduos in-sample artificialmente pequenos para 85% das observações — um vazamento que contaminava a Etapa 2 na versão anterior.

5. Etapa 2 — Double Machine Learning

O problema que o DML resolve

Queremos estimar o efeito causal θ de D (liquidez) em Y (sobreprego). Se fizéssemos só uma regressão $Y \sim D$, o coeficiente de D seria enviesado pelos confundidores W (clube rico, sazonalidade, etc.). Se adicionássemos W na regressão ($Y \sim D + W$), o problema seria:

1. A relação entre W e Y pode ser não-linear (Random Forest captura isso, OLS não)
2. Temos 19 confundidores — incluí-los em OLS aumenta o erro e pode criar overfitting

O **Double ML** (Chernozhukov et al., 2018) resolve os dois problemas com uma técnica elegante chamada **ortogonalização de Neyman**. A ideia em 3 passos:

Passo 1: Tire de Y o que os confundidores W explicam $\rightarrow$ resíduo $\tilde{Y} = Y - \hat{g}(W)$

Passo 2: Tire de D o que os confundidores W explicam $\rightarrow$ resíduo $\tilde{D} = D - \hat{m}(W)$

Passo 3: Estime θ pela regressão simples $\tilde{Y} \sim \theta \cdot \tilde{D}$

Por que isso funciona? $\tilde{Y}$ e $\tilde{D}$ são as partes de Y e D que os confundidores *não conseguem explicar*. Ao regredir $\tilde{Y}$ em $\tilde{D}$, estamos medindo a relação entre “variação de liquidez que não é explicada pelo porte do clube” e “variação de sobreprego que não é explicada pelo porte do clube”. Essa relação é, por construção, livre do confundidor $C1$.

O cross-fitting e por que é necessário

Se treinarmos $\hat{g}$ e $\hat{m}$ nos mesmos dados onde calculamos os resíduos, o modelo pode “memorizar” os dados de treino e os resíduos ficarão artificialmente pequenos — um tipo de overfitting que viesaria θ .

Cross-fitting (K=5 folds): dividimos os dados em 5 partes. Para cada parte, treinamos $\hat{g}$ e $\hat{m}$ nas outras 4 e calculamos os resíduos na parte deixada de fora. Ao final, temos resíduos out-of-sample para todas as observações — sem overfitting.

O vetor de confundidores W (19 variáveis)

Bloco	Variáveis	Confundidor controlado
Rede	in_degree, out_degree, pagerank	C1 (clube rico/prestígio), C6

Bloco	Variáveis	Confundidor controlado
Elenco	squad_size, average_age, national_team_players	C1, C6
Temporada	7 dummies (2018–2025)	C4 (sazonalidade), C5 (inflação)
Liga	6 dummies	C4, C5

Limitação importante: W não inclui total_spend, n_buys, net_balance (bloco financeiro direto). O confundidor C1 é controlado por *proxies* (centralidade na rede + tamanho do elenco), não pelo volume financeiro direto. Isso é uma limitação reconhecida — declaramos nas limitações.

O resultado principal: ATE = 0,0044 (não significativo)

ATE (Average Treatment Effect) = efeito médio causal. $\theta = 0,0044$ é uma **semielasticidade** (variação do sobrepreço por unidade-log de receita de vendas — não “por 1% de receita”).

O IC 95% cruza zero tanto com HC1 [−0,0016; 0,0104] quanto com erro-padrão clusterizado clube×temporada [−0,0021; 0,0110]. Não podemos rejeitar a hipótese de que o efeito médio é zero.

Por que clusterizar? D e W são constantes dentro de cada clube×temporada (só 974 clusters para 5.146 transferências). Tratar as 5.146 obs como independentes subestima os SE; por isso reportamos também o IC clusterizado, que é o nível de inferência correto.

Por que isso é um resultado válido e não uma falha?

Porque o contraste com a correlação ingênua revela algo importante:

Estimador	θ	IC 95% (HC1)	Significativo?
OLS sem controles ($Y \sim D$)	0,0142	[0,009; 0,019]	Sim
OLS com controles lineares	0,0051	[−0,000; 0,010]	Não
DML (não-linear)	0,0044	[−0,002; 0,010]	Não

A progressão é clara: à medida que controlamos os confundidores de forma cada vez mais adequada, o efeito estimado encolhe de 0,0142 para 0,0044 e perde significância. **Isso mostra que a correlação bruta (0,0142) era, em grande parte, o confundidor “clube rico” em ação.** O DML separou o efeito real do ruído de confundimento. (A correlação bruta também é significativa com SE clusterizado; o DML não.)

Os placebos: validando que o modelo não inventa efeito

Dois testes de sanidade:

Placebo 1 — D embaralhado: embaralhamos aleatoriamente quem recebeu qual valor de receita de vendas. Se o modelo encontrar um efeito aqui, ele está inventando efeito onde não há. Resultado: $\theta = 0,0024$ (IC cruza zero) 

Placebo 2 — D → ruído gaussiano: substituímos D por números aleatórios. Resultado: $\theta = 0,0009$ (IC cruza zero) ✓

Atenção: o placebo embaralhado deu $\theta = 0,0024$ — quase do tamanho do ATE real (0,0044). Isso reforça que o ATE **médio** é genuinamente nulo: o modelo mal distingue o tratamento real do ruído na amostra completa. (Esse placebo embaralha D globalmente, então testa o efeito médio, não o poder de detectar os efeitos sazonais de 2022/2023 — ver limitações.)

O R^2 da primeira etapa

Antes de estimar θ , o DML precisa que os modelos $\hat{g}$ e $\hat{m}$ funcionem minimamente bem:

- **R^2 model_t ($\hat{m}$) = 0,37:** os confundidores W explicam 37% da variância da receita de vendas. Razoável — o porte do clube prediz razoavelmente bem quanto ele vende.
- **R^2 model_y ($\hat{g}$) = 0,06:** os confundidores W explicam apenas 6% da variância do sobrepreço. Baixo, mas esperado: Y já é o resíduo da Etapa 1 (jogador foi removido). O que sobra é majoritariamente idiossincrático.

O achado central: θ por temporada

Quando olhamos o efeito separado por temporada, a história muda completamente:

(θ por temporada, IC clusterizado por clube; p_bonf = p-valor após Bonferroni para os 8 testes.)

Temporada	θ	IC 95% (cluster)	Sig.?	p_bonf	Contexto
2017	-0,006	[-0,026; 0,014]	Não	1,00	Mercado normal
2018	-0,013	[-0,036; 0,011]	Não	1,00	Mercado normal
2019	+0,024	[-0,011; 0,058]	Não	1,00	Mercado normal
2021	+0,012	[-0,001; 0,025]	Não	0,63	Pós-COVID (cautela)
2022	+0,064	[0,028; 0,101]	Sim	0,005	Boom pós-COVID
2023	+0,047	[0,017; 0,077]	Sim	0,019	Boom pós-COVID
2024	+0,003	[-0,053; 0,059]	Não	1,00	Normalização
2025	+0,015	[-0,010; 0,040]	Não	1,00	Normalização

2022 e 2023 sobrevivem à correção de Bonferroni E ao FDR — não são falsos-positivos do “garden of forking paths”. Este é o achado confirmatório mais forte sobre o efeito sazonal.

O que isso significa:

Em 2022 e 2023, o mercado de transferências viveu um boom sem precedentes após 2 anos de restrições pandêmicas. Os volumes bateram recordes. Nesse contexto de escassez de talento disponível e urgência generalizada de reposição, o prêmio do vendedor emergiu: clubes com liquidez pagavam significativamente acima do preço justo (efeito sazonal +0,064 em 2022 e +0,047 em 2023, ambos sobrevivendo a Bonferroni/FDR).

Nos outros 6 anos, o efeito é estatisticamente zero. A média das 8 temporadas dilui o efeito de 2022–2023 com 6 anos de zero — daí o ATE médio ser nulo.

Por que a versão de 3 temporadas parecia significativa? Porque usava 2023–2025, e 2023 era o ano mais forte. Com mais dados, o contexto ficou claro: não é sempre — é só quando o mercado aquece.

6. Testes de Robustez

O que são testes de robustez e por que fazemos

Um resultado robusto é aquele que não muda quando fazemos variações razoáveis na metodologia. Se o efeito desaparece quando mudamos levemente o tratamento ou a amostra, o resultado original não era confiável. Fizemos 4 tipos de teste.

Teste 1 — Tratamento Defasado (C2 — Causalidade Reversa)

O problema: medimos D (receita de vendas) e Y (sobrep preço das compras) na **mesma temporada**. Isso deixa a dúvida: e se o clube primeiro decidiu comprar caro e depois vendeu para pagar? Nesse caso, a compra causaria a venda — e não o contrário.

A solução: usamos a receita de vendas do **ano anterior** (t-1) como tratamento alternativo. A receita de t-1 é *predeterminada* em relação à compra de t — uma compra de 2024 não pode ter causado as vendas de 2023.

Resultado (SE clusterizado): $\theta_{\text{defasado}} = 0,0051^*$ (IC [0,0012; 0,0090]) — significativo.

O que significa: quando usamos a liquidez do ano anterior, o efeito persiste e é significativo. A direção “venda → prêmio” fica mais plausível e **a causalidade reversa (C2) enfraquece** — não eliminada.

Ressalva honesta: na *mesma* subamostra, o contemporâneo é **não significativo** ($\theta=0,0055$) mas o defasado é significativo. Isso é estranho se a história fosse puramente contemporânea — o lag provavelmente capta um **traço persistente de clube** (“clube que sempre vende”, $\text{corr}=0,44$), parte do confundidor de porte. Logo o teste é **direcionalmente tranquilizador, não conclusivo**.

Teste 2 — D Alternativo (Especificações do Tratamento)

O problema: medimos liquidez como $D = \log(\text{receita em euros})$. Mas e se o mecanismo for diferente? E se não for o volume de dinheiro, mas outra coisa?

Testamos 3 definições (SE clusterizado):

Tratamento	Interpretação	θ	Significativo?
$D_1 = \log(\text{receita } \text{€})$ — principal	Volume de dinheiro recebido	0,0044	Não
$D_2 = \log(n^\circ \text{ de vendas})$	Quantas vendas foram feitas	0,049	Sim
$D_3 = \text{flag de venda } > \text{€}30\text{M}$	Fez uma venda blockbuster?	0,075	Sim

Leitura inicial (sedutora, mas frágil): D_1 (volume em euros) não prediz sobrepreço, mas D_2 (número de vendas) e D_3 (venda blockbuster) sim. Isso *sugeria* que o mecanismo é “**sinalizar** que precisa comprar” (urgência de reposição / venda de ativo-chave), não o volume monetário.

⚠ **Teste do artefato “clube ativo” derruba a leitura.** Clubes com janela movimentada compram e vendem muito. Ao adicionar ao W controles de intensidade de janela ($n_buys + \log$ do gasto total), **D_2 e D_3 perdem completamente a significância** (D_2 : $\theta=0,015$, $p=0,40$; D_3 : $\theta=0,005$, $p=0,86$). Ou seja, o sinal de D_2/D_3 era em grande parte **intensidade de atividade**, não um canal causal limpo de sinalização.

Conclusão honesta: o “mecanismo de sinalização” é **exploratório e NÃO robusto** — não deve ser apresentado como achado confirmatório. Fica como hipótese a investigar com dados de melhor granularidade (datas diárias, urgência observável).

Teste 3 — Subgrupos por Tier de Liga

Dividimos as transferências em duas categorias:

- **Top-4:** Bundesliga, Premier League, La Liga, Serie A (3.450 obs) $\rightarrow \theta = 0,0041$ (n.s.)
- **Ligas menores:** Jupiler Pro League, Liga Portugal, Ligue-1 (1.696 obs) $\rightarrow \theta = 0,0106$ (n.s.)

O que significa: nenhum grupo tem efeito significativo na média das 8 temporadas — coerente com o ATE geral nulo. Mas a **direção** está certa: ligas menores têm θ maior, o que é consistente com a teoria (clubes de ligas menores são tipicamente vendedores e sofrem mais pressão de reposição). A falta de significância é provavelmente falta de poder estatístico (n menor).

Teste 4 — Placebos globais (já descrito na Etapa 2)

D embaralhado: $\theta = 0,0024$ (n.s.) 
D com ruído: $\theta = 0,0009$ (n.s.) 

Teste 5 — Placebo dentro da temporada (valida 2022/2023)

O placebo global só testa o efeito médio. Para testar o desenho **onde o efeito vive**, permutamos D **entre os clubes de 2022** (e de 2023), recalculamos θ e repetimos 200×. Resultado: o θ observado (+0,064 em 2022; +0,044 em 2023) fica muito além do percentil 97,5 da distribuição nula ($\sim +0,012$), com **p empírico = 0,005** para ambos. **É o placebo mais informativo do trabalho:** confirma que o efeito de 2022/2023 não é artefato do desenho.

Teste 6 — Sensibilidade ao corte de fee (viés de seleção, C6)

Filtrar por fee $\geq \text{€}250\text{k}$ poderia truncar a cauda esquerda (pechinhas) e enviesar o resultado. Reconstruímos o pipeline **inteiro** para os limiares €0/100k/250k/500k/1M:

Limiar	n	ATE	2022	2023
€0	5.339	+0,001 (n.s.)	+0,064*	+0,062*
€100k	5.291	+0,002 (n.s.)	+0,046*	+0,068*
€250k (principal)	5.146	+0,004 (n.s.)	+0,065*	+0,047*
€500k	4.915	+0,002 (n.s.)	+0,053*	+0,043*
€1M	4.506	+0,002 (n.s.)	+0,015 (n.s.)	+0,029*

O ATE é nulo em todos os limiares e 2022/2023 são estáveis de €0 a €500k. Baixar o corte para €0 (que reintroduz as pechinhas supostamente truncadas) não muda nada. **Os achados não são artefato do corte.**

Teste 7 — Sensibilidade à identificação (confundidor omitido)

A maior fragilidade causal é o confundidor omitido (W não tem o bloco financeiro direto). Dois testes:

- **Robustness Value (Cinelli & Hazlett, 2020):** um confundidor não-observado precisaria explicar **~24% (2023) a ~27% (2022)** da variação residual de *ambos* D e Y para anular o efeito — patamar alto, que confundidores plausíveis (UCL, troca de técnico) dificilmente atingiriam sozinhos.
- **Stress test (over-control financeiro):** ao incluir n_buys + log(gasto) no W (controles contemporâneos, parcialmente mediadores), **2023 sobrevive** ($\theta \approx +0,037$, $p \approx 0,003$) e **2022 atenua** para não-significativo ($\theta \approx +0,032$), mantendo o ponto positivo. 2023 é robusto até a over-control.

7. IVB — Índice de Vulnerabilidade de Barganha (apêndice exploratório)

O que é

O IVB pontua cada clube de 0 a 1 com base em quanto ele sofre o prêmio do vendedor quando tem liquidez. O CATE (efeito causal individual por clube, via R-learner) vira o IVB após normalização.

- **IVB ≈ 1 (“presa fácil”)**: clube que paga os maiores sobrepreços quando capitalizado
- **IVB ≈ 0 (“negociador disciplinado”)**: clube que não deixa a liquidez afetar suas compras

Normalização robusta (corrige o problema do outlier)

A versão antiga usava min-max: $(\theta_c - \min)/(\max - \min)$. Como o Nîmes (8 obs) tinha CATE altíssimo, o max explodia e comprimia todos os demais clubes perto de zero — a escala ficava sem sentido. **Trocamos por percentil**: $\text{IVB}_c = \text{percentil}(\bar{\theta}_c)$ entre os clubes elegíveis (≥ 3 transações). Como usa só a *ordenação*, a escala fica uniforme em $[0,1]$ e imune à magnitude do outlier. (Para o boxplot por liga usamos min-max winsorizado a p5–p95.)

Por que continua sendo só um apêndice

Mesmo com a escala corrigida, o **ordenamento** reflete CATEs ruidosos: o R^2 de 1ª etapa em Y é só 0,06, então há pouco sinal genuíno de heterogeneidade. O Nîmes segue nominalmente no topo (maior CATE pontual, mas com 8 obs). Soma-se a isso que o R-learner é uma aproximação do CausalForestDML (econml não instala no ambiente). Por tudo isso, o IVB é **apêndice ilustrativo / prova de conceito** — não deve ser usado como ferramenta de decisão.

O que seria se funcionasse corretamente

Com CausalForestDML, mais observações por clube e sinal de heterogeneidade real, o IVB seria uma ferramenta para um clube identificar rivais vulneráveis quando capitalizados, ou checar se ele mesmo é uma “presa fácil”. Fica como trabalho futuro.

8. Os Achados: 2 Confirmatórios + 1 Exploratório

Disciplina inferencial: tratamos como **confirmatório** apenas o que sobrevive a SE clusterizado e (no caso sazonal) à correção de múltiplas comparações. O resto é **exploratório / gerador de hipótese** e está rotulado como tal.

Achado 1 (confirmatório) — A Correlação Mente

OLS ingênuo: $\theta = 0,0142^*$ (significativo)

DML causal: $\theta = 0,0044$ (não significativo, inclusive com SE clusterizado)

A correlação bruta entre “recebeu de vendas” e “pagou sobrepreço” é $\sim 3\times$ maior que o efeito causal real — e enganosamente significativa. É o confundidor “clube rico” contaminando a correlação. Sem o Double ML, teríamos publicado um resultado falso.

Mensagem: correlação não é causalidade. O pipeline causal de duas etapas é o que torna o resultado defensável.

Achado 2 (confirmatório) — O Prêmio é Condicional ao Regime

Na média de 8 temporadas, o efeito é nulo. Mas em **2022 (+0,064*)** e **2023 (+0,047*)** — o boom pós-COVID — o prêmio emerge de forma significativa, **sobrevivendo a Bonferroni e FDR**. Nos outros 6 anos, não há efeito detectável.

Mensagem: o “efeito dominó” não é uma lei do mercado — é um fenômeno emergente em condições específicas de escassez e urgência. O timing importa.

Achado 3 (EXPLORATÓRIO, não robusto) — Sinalização vs. Volume

Na especificação bruta, o número de vendas (D_2 , +0,049*) e a venda blockbuster (D_3 , +0,075*) prediziam sobrepreço, enquanto o volume em euros (D_1) não — o que *sugeria* um mecanismo de “sinalização”. **Porém**, ao controlar por intensidade de janela ($n_buys + \text{gasto total}$), **D_2 e D_3 perdem toda a significância** ($p=0,40$ e $p=0,86$).

Mensagem honesta: o sinal de D_2/D_3 reflete em grande parte “clube com janela movimentada”, não um canal causal limpo de sinalização. **Este achado NÃO deve ser apresentado como confirmatório** — é uma hipótese a investigar com dados de melhor granularidade.

9. O Que Não Fizemos e Por Quê

É importante ser honesto sobre o que prometemos e não entregamos, para não ser pego de surpresa na banca.

PSM (Propensity Score Matching)

Prometemos: o checkpoint mencionava “clubes gêmeos” via PSM para validar C6 (viés de seleção).

Não fizemos porque: o PSM exige que tratados e controles tenham distribuições de confundidores sobreponíveis. Com 19 confundidores, o matching seria complexo e provavelmente reduziria muito a amostra. Com o tempo disponível, priorizamos o DML (que controla confundidores de forma mais flexível) e os testes de robustez.

Como responder na banca: “O PSM foi substituído pelo controle não-paramétrico via DML, que trata os confundidores de forma mais flexível. Está declarado como trabalho futuro.”

FBref / StatsBomb (dados de performance)

Prometemos: integrar gols, xG, assistências, minutagem para melhorar o modelo hedônico.

Não fizemos porque: o entity matching entre Transfermarkt e FBref exige reconciliar IDs de jogadores entre os dois sistemas — um processo demorado e sujeito a erros. Com o $R^2 = 0,762$ já na faixa da literatura, a prioridade foi a robustez causal, não o refinamento do hedônico.

Como responder na banca: “O R^2 de 0,762 está na faixa esperada pela literatura (0,70–0,80). A performance individual enriqueceria o hedônico mas está além do escopo atual.”

econml / CausalForestDML

Prometemos: usar CausalForestDML do econml para o IVB.

Não fizemos porque: incompatibilidade de build no ambiente (Python 3.12 + NumPy 2.x). O R-learner foi usado como substituto para o CATE/IVB. O ATE e os testes de robustez usam DML manual que é equivalente ao econml para o modelo parcialmente linear.

Como responder na banca: “O ATE e a robustez foram calculados com DML manual validado (reproduz o econml dentro de erro de arredondamento). O IVB é ilustrativo — declaramos essa limitação explicitamente.”

Análise do lado vendedor (“clubes predadores”)

O IVB mede quem é vulnerável quando compra. A análise simétrica seria: quais clubes se aproveitam melhor quando o outro lado está capitalizado e urgente? Isso não foi implementado — mencionamos como trabalho futuro.

10. Glossário Rápido

Termo	Definição simples
Modelo hedônico	Modelo que prevê o preço de um bem pelos seus atributos. Aqui: preço do jogador pelos seus atributos esportivos.
Resíduo hedônico	Diferença entre o preço pago e o preço previsto pelo modelo. Nosso Y = o sobrepreço.

Termo	Definição simples
ATE	Average Treatment Effect — efeito médio causal do tratamento (liquidez) sobre o resultado (sobrepço).
CATE	Conditional Average Treatment Effect — efeito causal estimado individualmente para cada clube/observação.
DML	Double Machine Learning — método causal que usa dois modelos ML para eliminar confundidores não-lineares.
Ortogonalização de Neyman	A técnica dentro do DML de tirar o efeito de W de Y e de D antes de estimar θ .
Cross-fitting	Técnica de dividir os dados em K folds para evitar overfitting nos modelos de primeira etapa do DML.
HC1	Tipo de erro-padrão robusto à heterocedasticidade. Mais conservador que o SE clássico.
Confundidor	Variável que afeta tanto o tratamento quanto o resultado, criando correlação espúria.
Causalidade reversa (C2)	Quando o resultado causa o tratamento, não o contrário. Aqui: “comprou caro então vendeu” ao invés de “vendeu então comprou caro”.
R-learner	Algoritmo de CATE que segue a lógica do DML mas estima efeitos individuais. Usado como substituto do CausalForestDML.
IVB	Índice de Vulnerabilidade de Barganha — score 0–1 do quanto cada clube sofre o prêmio quando capitalizado.
PageRank	Métrica de centralidade em grafo. Aqui: importância estrutural do clube na rede de transferências.
Big sale flag	Variável binária: 1 se o clube fez uma venda única acima de €30M na temporada.
Split temporal	Divisão de dados onde treino = passado e teste = futuro. Mais honesto que divisão aleatória para dados com tendência temporal.
Winsorização	Truncar os extremos da distribuição (aqui, percentis 1% e 99%) para reduzir o impacto de outliers.
SHAP	Técnica de interpretabilidade que calcula a contribuição de cada feature para cada predição individual.
IC 95%	Intervalo de Confiança de 95%. Se cruza zero, o efeito não é estatisticamente significativo a 5%.

Documento gerado em 18/06/2026. Dúvidas: releia as seções relevantes ou consulte os notebooks em [notebooks/](#) e a documentação técnica em [knowledge/](#).